

Detección de alucinaciones en sistemas RAG
mediante
aprendizaje automático clásico
Capítulo de resultados (caso de estudio)

Raquel García Hernández

Capítulo 1

Resultados

El propósito de este capítulo es reconstruir, paso a paso, el camino que lleva desde la definición del problema hasta un detector de alucinaciones válido y honesto. No presentamos solo el modelo final: mostramos primero cada exploración con sus cifras, incluidas las que fracasaron, y para cada decisión justificamos la opción con la que nos quedamos. El orden reproduce la forma en que un problema de aprendizaje automático se ataca en la práctica. Empezamos por entender los datos y su desbalance, seguimos por la ingeniería y la selección de características, tratamos después el desbalance de clases como un problema de decisión, comparamos los cinco clasificadores clásicos bajo una evaluación sin fugas y cerramos situando el resultado frente al estado del arte. Todas las cifras salen de la librería del proyecto con semilla fija, y cada tabla tiene su fuente única en los informes de `outputs/reports/`.

1.1. Definición del problema y protocolo

Un sistema de generación aumentada por recuperación (RAG) responde a una consulta apoyándose en un documento fuente recuperado [14]. La respuesta alucina cuando afirma algo que la fuente no respalda [12]. Nuestro objetivo es construir un clasificador que, dado el par (respuesta, fuente), decida si la respuesta contiene alguna alucinación, usando exclusivamente aprendizaje automático clásico y características léxicas y estadísticas, sin redes neuronales ni llamadas a ningún modelo de lenguaje. La motivación es reproducir, a coste mil veces menor, lo que hoy hace un evaluador tipo *LLM como juez*, con un modelo interpretable y determinista.

La hipótesis falsable que fijamos al inicio es que un clasificador clásico sobre estas características alcanza un AUC-ROC de al menos 0,80 sobre RAGTruth con evaluación honesta. El AUC-ROC [9] es nuestra métrica in-

terna porque no depende del umbral de decisión y mide la separación pura entre clases. Ahora bien, el estado del arte sobre RAGTruth no publica AUC, sino F1 a nivel de respuesta y accuracy. La comparación externa, por tanto, se hace en F1 y accuracy, y siempre sobre el mismo conjunto de test oficial que usa la literatura.

El protocolo de evaluación es la parte más delicada. Para seleccionar modelos, umbrales y características validamos con **GroupKFold** agrupando por documento fuente, de modo que ninguna fuente aparece a la vez en entrenamiento y validación; un **KFold** aleatorio filtraría información entre particiones e inflaría el resultado. Para reportar la cifra que compite con la literatura evaluamos sobre el split oficial de test de RAGTruth, que permanece intacto durante todo el desarrollo. Cualquier transformación con parámetros, como la vectorización TF-IDF, se ajusta solo con entrenamiento. La semilla es 42 en todo el flujo.

1.2. La base de datos: RAGTruth

RAGTruth [15] es un corpus de salidas de modelos de lenguaje anotadas por humanos, tramo a tramo, según contengan o no alucinaciones. Reúne alrededor de 17 790 respuestas sobre 2 965 prompts, generadas por varios modelos y repartidas en tres tareas: respuesta a preguntas (QA), generación a partir de datos estructurados (Data2txt) y resumen de documentos (Summary, con fuente en CNN/DailyMail). A partir de las anotaciones **hallucination_labels** construimos una etiqueta binaria por respuesta: positiva si existe al menos un tramo alucinado. El corpus distingue además cuatro tipos de alucinación, cruzando dos ejes: evidente frente a sutil, e información inventada frente a conflicto directo con la fuente.

Trabajamos con la partición oficial: 15 090 respuestas de entrenamiento y 2 700 de test. La prevalencia global de alucinación es del 44,5 % en entrenamiento y del 34,9 % en test. Esta diferencia no es un detalle: adelanta que la proporción de positivos se desplaza entre las dos particiones, un fenómeno que gobierna buena parte de los resultados posteriores.

1.3. Descriptivo de los datos

1.3.1. Desbalance de clases: global y por tarea

El desbalance global es moderado, pero engaña. Al abrir la prevalencia por tarea aparece la estructura real del problema, que resumimos en el Cuadro 1.1 y en la Figura 1.1. Data2txt es mayoritariamente positiva, con casi

dos de cada tres respuestas alucinadas; QA y Summary son minoritariamente positivas, y su prevalencia cae aún más en el test.

Tarea	prevalencia (train)	prevalencia (test)
Data2txt	0,694	0,643
QA	0,311	0,178
Summary	0,311	0,227
Global	0,445	0,349

Tabla 1.1: Prevalencia de alucinación por tarea. La proporción de positivos difiere entre tareas y se desplaza entre entrenamiento y test, de forma desigual en cada una.





Figura 1.1: Prevalencia por tarea en entrenamiento y test. El desplazamiento del prior es mayor en QA (0,311 a 0,178), lo que dejará un umbral global demasiado alto para esa tarea.

Estamos ante un desbalance heterogéneo por subgrupo y con desplazamiento de prior. La consecuencia práctica se anticipa aquí: un único umbral de decisión no puede ser óptimo para prevalencias tan dispares, y el tratamiento del desbalance no será un ajuste global sino una decisión por tarea. La distribución de longitudes por clase (Figura 1.2) y el reúso de documentos, que motiva el GroupKFold, completan el retrato del conjunto.



(a) Balance global de clases (train). (b) Longitud de la respuesta por clase.

Figura 1.2: Descriptivo global del conjunto de entrenamiento.

1.3.2. Caracterización del fenómeno: los tramos alucinados

Antes de modelar conviene entender qué aspecto tiene una alucinación. Analizamos los tramos anotados en su posición dentro de la respuesta, su longitud, su categoría gramatical, el tipo de entidad que contienen y el tipo de alucinación (Figura 1.3). Dominan las alucinaciones de números, fechas y nombres propios, lo que justifica de forma natural las características de solape numérico y de entidades. La composición por tipo revela un dato que gobierna el capítulo de error: Summary es en un 86 % de tipo evidente, y sin embargo, como veremos, es la tarea más difícil. El tipo anotado no explica la dificultad.




Figura 1.3: Descriptivo de los tramos alucinados. Predominan números y entidades; Summary es mayoritariamente de tipo evidente pese a ser la tarea difícil.

1.4. Exploración de características

1.4.1. Catálogo de características

Construimos la matriz de diseño con tres bloques. El primero son nueve características escalares sobre el par (respuesta, fuente), que capturan solape léxico, consistencia numérica y recombinación. El segundo agrega el soporte por frase, con la intuición de que una alucinación suele ser una frase sin respaldo dentro de una respuesta por lo demás correcta, y que un promedio sobre toda la respuesta la diluye; por eso agregamos con el mínimo, que delata la frase peor sostenida. El tercero es la codificación *one-hot* de la tarea, que permite al modelo especializar su respuesta por tipo de tarea. El Cuadro 1.2 recoge las dieciocho características.

Bloque	Características
Escalares (9)	<code>containment</code> (precisión léxica $ R \cap F / R $), <code>jaccard</code> , <code>tfidf_cos</code> (coseno TF-IDF ajustado por par), <code>num_overlap</code> (números de la respuesta presentes en la fuente), <code>novel_bigram</code> , <code>novel_trigram</code> (recombinación de n -gramas), <code>num_context</code> (consistencia número-unidad), <code>neg_diff</code> (diferencia de negación), <code>answer_len</code>
Nivel frase (6)	<code>sent_cont_min</code> , <code>sent_cont_mean</code> , <code>sent_cont_std</code> , <code>sent_frac_low</code> , <code>sent_sim_min</code> , <code>sent_sim_mean</code>
One-hot tarea (3)	<code>task_QA</code> , <code>task_Summary</code> , <code>task_Data2txt</code>

Tabla 1.2: Las dieciocho características. R y F son los conjuntos de palabras únicas de respuesta y fuente. El coseno TF-IDF sigue el modelo de espacio vectorial [19].

La característica `containment`, la fracción de palabras de la respuesta que aparecen en la fuente, es la señal dominante, y su signo es el esperado: más solape léxico implica menos probabilidad de alucinación. La codificación de tarea y el coseno TF-IDF se mantienen en el modelo por su papel funcional, la primera para especializar por tarea y la segunda como medida semántica clásica, aunque su aporte marginal sea pequeño una vez presente `containment`, como cuantificamos más abajo. La separabilidad univariada de cada característica por clase aparece en la Figura 1.4.




Figura 1.4: Distribución de cada característica separada por clase. **containment** y las medidas de solape muestran el mayor desplazamiento entre limpio y alucinado.

1.4.2. Características probadas y descartadas


La exploración de características incluye varias vías que no funcionaron. Las documentamos porque forman parte de la caracterización del techo del problema: no es que no se intentara. El Cuadro 1.3 recoge cada vía y la cifra que la descartó, siempre medida con el protocolo honesto.

Vía	Qué es	Resultado
LSA	TF-IDF con descomposición en valores singulares truncada [7, 11], ajustada por partición	+0,001 de AUC global; redundante con containment
sent_novel	Novedad de n -gramas agregada por frase	+0,001 global; el resumen fiel recombina igual que el alucinado
Estructura sintáctica	Arcos de dependencia, sujeto-verbo-objeto y enlace entidad-número con spaCy	Summary 0,701 → 0,700

Tabla 1.3: Vías de características exploradas y descartadas. Cuatro familias distintas, solape léxico, similitud por frase, recombinación de n -gramas y estructura sintáctica, fracasan por el mismo motivo en Summary: resumir es recombinar, y el texto fiel comparte la firma de superficie con el alucinado.

1.4.3. Redundancia y selección de variables

Con dieciocho características cabe preguntarse si sobran. Tres análisis convergen en que sí hay redundancia, pero no sobreajuste peligroso. La correlación de Spearman (Figura 1.5a) muestra que el bloque de solape está muy correlacionado, con pares como `novel_bigram` y `novel_trigram` en 0,98; hay del orden de dos o tres señales independientes en trece características. Una selección hacia delante por modelo aplanan la curva de F1 pronto, con una rodilla alrededor de ocho características (Figura 1.6). Y al comparar el modelo podado con el completo en el test oficial, pasar de siete a dieciocho características aporta 0,006 de AUC y 0,004 de F1, dentro del ruido.



(a) Correlación de Spearman entre características.

(b) Rendimiento frente a número de características (test).

Figura 1.5: Redundancia y parsimonia. Siete características igualan a las dieciocho.






Figura 1.6: Selección hacia delante (XGBoost). Cada métrica frente a la incorporación ordenada de características. La curva se satura pronto: **containment** carga con casi toda la señal.

1.4.4. Qué características explican el rendimiento

La importancia por permutación mide cuánto cae el AUC real al romper cada característica. El resultado es contundente: **containment** explica unas ocho veces más que la siguiente (Figura 1.7). Rompiéndola, el AUC cae dieciséis puntos; rompiendo cualquier otra, menos de dos. La importancia acumulada cruza el 80 % con muy pocas características. Al desglosar por tarea aparece un matiz valioso: en Data2txt la característica relacional **num_context** es la primera, por encima de **containment**, porque la consistencia número-unidad es lo que caza las cifras fabricadas; en QA y Summary casi todo depende del solape léxico.



(a) Importancia por permutación (caída de AUC).



(b) Importancia acumulada.

Figura 1.7: Una única característica léxica trivial carga con casi toda la señal, lo que da al detector su carácter interpretable.

Decisión. Mantenemos el conjunto completo de dieciocho características como base del detector, con la codificación de tarea y el coseno TF-IDF incluidos por su papel funcional. La redundancia está caracterizada y, si se busca parsimonia, siete características reproducen el rendimiento; conservamos las demás porque en el test no penalizan y aportan interpretabilidad por tarea.

1.5. Tratamiento del desbalance de clases

1.5.1. Diagnóstico: dos poblaciones de falsos negativos

El detector deja pasar demasiadas alucinaciones, y esta es la preocupación central del capítulo. Antes de tratar el desbalance, distinguimos dos causas de falso negativo que exigen remedios distintos. El análisis de error por tarea (Figura 1.8) lo separa con claridad.

La primera población vive en QA. Su AUC es 0,822, el mejor de las tres tareas, de modo que el modelo ordena las alucinaciones casi a la perfección; sin embargo, con un umbral global solo recupera el 54 % de ellas. Esto no es un problema de señal, sino de decisión: el umbral, calibrado para una prevalencia media, es demasiado alto para una tarea con solo un 18 % de positivos.

La segunda población vive en Summary, y sí es un problema de señal. El texto alucinado de un resumen reutiliza el vocabulario del documento, así que

comparte palabras con la fuente aunque el error sea evidente. Lo confirmamos midiendo el solape del propio tramo alucinado contra la fuente: en Summary es 0,62 de mediana, frente a 0,43 en Data2txt, y dentro de Summary los falsos negativos tienen más solape (0,641) que los aciertos (0,555). El modelo falla justo en los tramos camuflados, y ninguna característica de superficie los distingue del texto fiel.





Figura 1.8: El cuello de botella de Summary es el camuflaje léxico, no el tipo de alucinación. El tramo alucinado de un resumen comparte firma léxica con el texto fiel.

1.5.2. El umbral de decisión


Si una parte de los falsos negativos es cuestión de umbral, la primera palanca es el umbral mismo. Comparamos tres criterios, todos con los umbrales fijados en el entrenamiento y aplicados al test: el índice de Youden global, que es el criterio de partida; el máximo de F1 por tarea; y el máximo de F2 por tarea, que pondera el recall cuatro veces más que la precisión y penaliza el falso negativo. El Cuadro 1.4 recoge el efecto por tarea, y la Figura 1.9a muestra cómo cada métrica cambia al mover el umbral.

Estrategia	ámbito	F1	precisión	recall	accuracy	FN
Youden global	Global (pooled)	0,682	0,684	0,680	0,779	302
	Data2txt	0,821	0,765	0,884	0,751	67
	QA	0,513	0,486	0,544	0,817	73
	Summary	0,287	0,472	0,206	0,768	162
Por tarea (max-F1)	Global (pooled)	0,656	0,547	0,821	0,700	169
	Data2txt	0,821	0,766	0,884	0,752	67
	QA	0,492	0,357	0,794	0,709	33
	Summary	0,453	0,344	0,662	0,638	69
Por tarea (max-F2)	Global (pooled)	0,577	0,409	0,982	0,497	17
	Data2txt	0,786	0,648	1,000	0,650	0
	QA	0,391	0,244	0,981	0,457	3
	Summary	0,407	0,261	0,931	0,386	14

Tabla 1.4: Estrategias de umbral sobre el test oficial. El umbral por tarea recupera el 44 % de los falsos negativos (de 302 a 169) y triplica el recall de Summary, a costa de precisión. F2 lleva el recall casi a uno pero hunde la accuracy.



(a) Barrido de umbral (OOF de train).



(b) Estrategias por tarea (test).

Figura 1.9: El umbral desliza el punto de operación entre precisión y recall. Un umbral por tarea reconoce que cada tarea tiene una prevalencia distinta.

El F1 global admite dos lecturas que conviene separar. El F1 *pooled*, calculado sobre todas las respuestas juntas, baja con el umbral por tarea, de 0,682 a 0,656, porque la caída de precisión pesa en el agregado. El F1 *macro*, media de los tres F1 por tarea, sube de 0,540 a 0,589, porque recompensa la mejora en Summary. Reportamos los dos: el pooled es el que suele dar la literatura, y el macro refleja mejor la mejora donde importa.

Aquí surge una tentación que conviene desmentir. Fijar el umbral por máximo de F1 no da un premio gratis en el agregado: el máximo de F1 global fijado en entrenamiento generaliza peor al test que Youden, porque la prevalencia de entrenamiento (0,445) no es la del test (0,349), y el umbral bajo que maximiza F1 en entrenamiento resulta demasiado agresivo fuera. La ganancia real del umbral por tarea no es en F1 pooled, sino en recall y en el F1 de la tarea difícil.

1.5.3. Corrección de prior de Saerens

Si el problema de QA es que la prevalencia del test difiere de la del entrenamiento, un remedio más principiado que mover el umbral a mano es corregir el prior. El método de Saerens [18] estima la prevalencia del test sin usar sus etiquetas, por un procedimiento de esperanza-maximización sobre los propios scores, y reajusta el posterior del clasificador a esa prevalencia. Lo probamos sobre probabilidades ya calibradas por regresión isotónica.

El método colapsa. La estimación por esperanza-maximización converge a priores degenerados: 1,000 en Data2txt, 0,000 en QA y 0,000 en Summary, frente a los reales 0,643, 0,178 y 0,227 (Figura 1.10). Con priores 0 y 1 la decisión se vuelve trivial, todo alucinado en Data2txt y nada en QA ni Summary. La causa es que las distribuciones de score de las dos clases se solapan demasiado, sobre todo en Summary, para que el procedimiento identifique la proporción de mezcla. La vía queda descartada con evidencia.




Figura 1.10: Corrección de prior de Saerens. El prior estimado por esperanza-maximización colapsa a 0 o 1 y no recupera la prevalencia real. Resultado negativo.

1.5.4. Remuestreo y aprendizaje sensible al coste

Queda la idea más intuitiva: reequilibrar las clases antes de entrenar, igualando las alucinaciones por tarea. Probamos sobremuestreo aleatorio, submuestreo aleatorio y SMOTE [2], siempre por tarea y solo en entrenamiento, y también el aprendizaje sensible al coste, que penaliza el falso negativo con un peso de clase. La pregunta correcta no es qué le pasa al F1 a un umbral fijo, sino si el tratamiento mueve la frontera, es decir, la separación real entre clases medida por el AUC-PR, que no depende del umbral.

Estrategia	Data2txt	QA	Summary
Base (sin tratar)	0,858	0,528	0,410
Sobremuestreo por tarea	0,853	0,532	0,390
Submuestreo por tarea	0,854	0,543	0,409
SMOTE por tarea	0,855	0,533	0,357
Sensible al coste	0,857	0,528	0,403

Tabla 1.5: AUC-PR por tarea según el tratamiento del desbalance en el entrenamiento. Ninguna variante mueve la frontera; SMOTE la empeora en Summary. Reequilibrar clases no crea señal.

El Cuadro 1.5 y la Figura 1.11a lo muestran sin ambigüedad: la frontera por tarea no se mueve, y SMOTE la empeora en Summary. El AUC-PR global cae con el remuestreo por tarea porque distorsiona la ordenación entre tareas. Lo que SMOTE parece ganar a un umbral fijo, subir el recall de Summary, es un espejismo: entrena a 50/50, infla los scores y hace que el mismo umbral actúe como uno más bajo. El modelo limpio con umbral por tarea lo domina, con mejor F1 de Summary (0,453 frente a 0,429), menos falsos negativos y mejor frontera. La Figura 1.11b resume la comparación en la moneda que nos importa, los falsos negativos totales.




Figura 1.11: El remuestreo no mueve la frontera. El umbral por tarea recupera más falsos negativos que SMOTE, sobre una frontera mejor.

Las matrices de confusión por tarea (Figura 1.12) cierran el argumento visualmente: al pasar del umbral global al umbral por tarea, los falsos negativos de QA bajan de 73 a 33 y los de Summary de 162 a 69, a cambio de más falsos positivos.



Figura 1.12: Matrices de confusión por tarea (XGBoost, test oficial). La fila superior usa umbral global; la inferior, umbral por tarea. La diagonal de aciertos de alucinación crece en QA y Summary.

Decisión. Adoptamos como punto de operación el umbral por tarea que maximiza F1, fijado en el entrenamiento. Es la única palanca honesta contra los falsos negativos: recupera el 44 % de ellos y hace competitivo el F1 de Summary sin tocar las características ni el modelo. Descartamos, con prueba, la corrección de prior de Saerens, el remuestreo en sus tres variantes y el aprendizaje sensible al coste, porque no mueven la frontera.


1.6. Modelos y evaluación honesta

Evaluamos cinco clasificadores clásicos: regresión logística [6], k vecinos más cercanos [5], máquina de vectores de soporte [4], bosque aleatorio [1] y gradient boosting sobre árboles [10, 3]. Cada uno se ajusta por búsqueda en rejilla con `GroupKFold`, y se evalúa sobre el test oficial. El Cuadro 1.6 recoge las métricas por secciones, con el umbral por Youden y el intervalo de confianza del AUC por bootstrap [8].

Modelo	AUC-ROC	IC 95 %	AUC-PR	F1	precisión	recall	ECE
Random Forest	0,836	[0,820, 0,851]	0,745	0,680	0,651	0,710	0,069
XGBoost	0,835	[0,819, 0,849]	0,748	0,684	0,698	0,671	0,063
KNN	0,826	[0,810, 0,841]	0,735	0,678	0,628	0,737	0,065
SVM	0,819	[0,801, 0,837]	0,732	0,692	0,700	0,685	0,068
Regresión logística	0,816	[0,800, 0,832]	0,711	0,670	0,643	0,700	0,111

Tabla 1.6: Comparativa de los cinco modelos en el test oficial (umbral por Youden). El AUC supera el umbral 0,80 de la hipótesis. XGBoost combina buen AUC con la mejor calibración.

Los cinco modelos superan el umbral 0,80 de la hipótesis falsable. Las diferencias entre ellos son pequeñas y sus intervalos de confianza se solapan. Elegimos XGBoost como modelo de referencia porque combina un AUC entre los mejores con la mejor calibración, medida por el error de calibración esperado. Las curvas ROC y precisión-recall, tanto en validación cruzada como en el test oficial, aparecen en la Figura 1.13.



(a) Curvas ROC (test oficial).

(b) Curvas precisión-recall (test oficial).

Figura 1.13: Discriminación de los cinco modelos sobre el test oficial.

El desglose por tarea (Figura 1.14a) confirma el diagnóstico: Data2txt y QA se separan bien, con AUC en torno a 0,78 y 0,82, mientras Summary se queda en 0,70. La paradoja de que QA tenga el mejor AUC y a la vez un F1 modesto se explica por la prevalencia, no por la separación. La calibración (Figura 1.14b) es razonable en crudo y mejora con regresión isotónica [16], lo que da probabilidades fiables para fijar el umbral.




Figura 1.14: Evaluación desagregada y calibración de XGBoost sobre el test oficial.

1.7. Comparación con el estado del arte

Situamos por fin el detector frente a la literatura sobre RAGTruth, que se mide en F1 a nivel de respuesta y en accuracy, no en AUC. El Cuadro 1.7 y la Figura 1.15 recogen la comparación por tarea. Nuestras cifras son las del punto de operación por tarea sobre el test oficial.

Método	QA	Data2txt	Summary	Global
GPT-4-turbo (juez)	45,6	78,3	47,6	63,4
Luna (encoder ligero)	51,3	75,9	52,5	65,4
LettuceDetect-large (396M)	70,2	88,5	59,7	79,2
Fine-tuned Llama-2-13B	68,2	88,1	59,1	78,7
RAG-HAT (mejor)	74,8	91,6	67,6	83,9
Este trabajo (clásico)	49,2	82,1	45,3	65,6 / 68,4

Tabla 1.7: F1 a nivel de respuesta (%) sobre RAGTruth, recopilado por Kovács et al. [13], con RAG-HAT [20] como cota alta. Nuestra columna global da el F1 macro por tarea (65,6) y el F1 pooled con umbral de Youden (68,4). El patrón universal se repite: Data2txt fácil, QA y Summary difíciles.




Figura 1.15: F1 por tarea, nuestro detector clásico frente a la literatura. La brecha se concentra en Summary, la tarea que nadie resuelve con solvencia.

La lectura honesta es doble. En F1 global superamos al juez GPT-4-turbo (63,4) y a Luna (65,4), y quedamos unos diez puntos por debajo de los modelos ajustados, LettuceDetect (79,2), Llama-2-13B (78,7) y RAG-HAT (83,9). En accuracy sobre el subset RAGTruth, la referencia es Lynx [17], con Lynx-8B en 80,0 y GPT-4o en 84,3, mientras nuestra accuracy ronda 0,74–0,78. El patrón por tarea es el mismo para todos: Data2txt alrededor del 88–92 %, QA y Summary mucho más bajos. Chocamos contra el mismo muro que modelos de miles de millones de parámetros, solo un poco antes. Un detalle refuerza el valor del resultado: trabajos que analizan RAGTruth por activaciones sostienen que la etiqueta apenas se correlaciona con diferencias de texto de superficie, de modo que alcanzar 0,82–0,84 de AUC con características léxicas no es trivial.

1.8. Conclusiones

Recogemos las conclusiones objetivo por objetivo, como cierre del caso de estudio.

Hipótesis falsable. Se cumple. Los cinco clasificadores clásicos superan el AUC-ROC de 0,80 sobre el test oficial de RAGTruth con evaluación honesta,

y el mejor alcanza 0,836. Un clasificador clásico sobre características léxicas separa alucinación de texto fiel con solvencia.

Falsos negativos y desbalance. El déficit de recall no se debía a las características ni al balance de clases, sino al punto de decisión bajo un desbalance heterogéneo y con desplazamiento de prior. Un umbral por tarea recupera el 44 % de los falsos negativos y hace competitivo el F1 de Summary. La corrección de prior de Saerens, el remuestreo y el aprendizaje sensible al coste se descartaron con evidencia por no mover la frontera.

El techo de Summary. Está caracterizado, no supuesto. Cuatro familias de características fracasan en Summary por la misma razón: resumir es recombinar, y el texto fiel comparte la firma léxica con el alucinado. Es la frontera entre la minería clásica de superficie y la semántica profunda, y el estado del arte, con modelos mucho mayores, tropieza con el mismo muro.

Posicionamiento. El detector rinde por encima del juez GPT-4-turbo y de Luna, y a unos diez puntos de los detectores ajustados, a coste cero, en CPU, de forma interpretable y determinista. Reproduce a bajo coste lo que hoy hace un evaluador basado en modelos de lenguaje, y acota con precisión hasta dónde llega lo léxico.

Bibliografía

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1), 2001.
- [2] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 2002.
- [3] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [4] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3), 1995.
- [5] Thomas M. Cover and Peter E. Hart. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 1967.
- [6] David R. Cox. The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B*, 20(2), 1958.
- [7] Scott Deerwester, Susan T. Dumais, George W. Furnas, Thomas K. Landauer, and Richard Harshman. Indexing by latent semantic analysis. *Journal of the American Society for Information Science*, 41(6), 1990.
- [8] Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1), 1979.
- [9] Tom Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 2006.
- [10] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 2001.
- [11] Nathan Halko, Per-Gunnar Martinsson, and Joel A. Tropp. Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review*, 53(2), 2011.

- [12] Ziwei Ji, Nayeon Lee, Rita Frieske, et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 2023.
- [13] Ádám Kovács and Gábor Recski. LettuceDetect: A hallucination detection framework for RAG applications. *arXiv preprint arXiv:2502.17125*, 2025.
- [14] Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [15] Cheng Niu, Yuanhao Wu, Juno Zhu, Siliang Xu, KaShun Shum, Randy Zhong, Juntong Song, and Tong Zhang. RAGTruth: A hallucination corpus for developing trustworthy retrieval-augmented language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.
- [16] John Platt. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In *Advances in Large Margin Classifiers*, 1999.
- [17] Selvan Sunitha Ravi, Bartosz Mielczarek, Anand Kannappan, et al. Lynx: An open source hallucination evaluation model. *arXiv preprint arXiv:2407.08488*, 2024.
- [18] Marco Saerens, Patrice Latinne, and Christine Decaestecker. Adjusting the outputs of a classifier to new a priori probabilities: A simple procedure. *Neural Computation*, 14(1), 2002.
- [19] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 1988.
- [20] Juntong Song, Xingguang Wang, Juno Zhu, et al. RAG-HAT: A hallucination-aware tuning pipeline for LLM in retrieval-augmented generation. In *Proceedings of EMNLP 2024 (Industry Track)*, 2024.